

PathoSAEv3 실험 지표 및 검증 프레임워크

(해석가능성 + 의학적 증빙성 중심)

버전: v1

작성일: 2026-02-25

본 문서는 PathoSAEv3 논문에서 사용할 실험/검증 지표를 정리하고, 첨부된 3 개의 SAE 관련 논문에서 사용된 검증 방법을 PathoSAEv3 에 도입하는 방법을 ‘왜 필요한가-어떻게 테스트하는가-PathoSAEv3 에 어떻게 구현하는가’ 관점에서 설계한다.

목차

1. 문서 목적과 사용 방법
2. PathoSAEv3 요약 (현재 설계 기준)
3. 평가 목표를 6 가지로 분해
4. (공통) 재구성/희소성/안정성 지표
5. 논문 A - CytoSAE 에서 가져올 수 있는 지표와 테스트
6. 논문 B - Pathology FM SAE Utility(PLUTO-SAE)에서 가져올 수 있는 지표와 테스트
7. 논문 C - VLM SAE Monosemanticity(MS 지표)에서 가져올 수 있는 지표와 테스트
8. 추가 제안: SAE/XAI/Medical 에서 설득력을 높이는 지표 묶음
9. PathoSAEv3 에 도입하는 전체 실험 설계(권장 최소 세트 + 확장 세트)
10. 구현 큰그림 (모듈, 데이터, 산출물, 시각화 템플릿)
11. 체크리스트 (논문 제출용)
12. 참고 문헌 / 출처

1. 문서 목적과 사용 방법

PathoSAEv3는 병리 파운데이션 모델(EXAONEPath)의 내부 표현(768-dim)을 Sparse Autoencoder(SAE)로 분해하여 ‘사람이 해석 가능한 형태학적 특징(dictionary)’로 바꾸는 것을 목표로 한다. 하지만 논문에서 설득력을 얻으려면 단순히 ‘그럴듯한 패치가 보인다’ 수준을 넘어, 해석가능성(interpretability)과 임상적 유용성(clinical utility)을 체계적으로 증명해야 한다.

1.1 이 문서가 제공하는 것

- 첨부 논문 3 편(CytoSAE, PLUTO 기반 Pathology SAE Utility, VLM SAE Monosemanticity)에서 사용한 실험/검증 지표의 정리
- 각 지표가 왜 필요한지(해석가능성, 일반화, 임상적 증빙), 어떤 테스트로 계산되는지
- PathoSAEv3(4 개 SAE variant 비교, 196 spatial tokens, 24,576 latents)에 맞게 도입하는 구체적 절차
- 논문에 바로 넣을 수 있는 시각화 템플릿(어떤 그림을 만들고 무엇을 보여줘야 하는지)
- 코드 구현 큰그림(모듈 구성, 데이터 흐름, 실험 설계/체크리스트)

1.2 용어 정리

- Backbone/FM: EXAONEPath 같은 병리 파운데이션 모델(ViT)에서 추출한 임베딩/토큰.
- SAE latent neuron/feature: SAE 의 잠재 차원 하나(예: 24,576 개 중 i 번째).
- Top-activating patches: 특정 latent 가 가장 크게 활성화되는 이미지 패치(타일) 상위 K 개.
- HIF(Human-interpretable feature): 사람/도구가 계산한 해석 가능한 수치(예: 특정 세포 수, 핵 면적).
- Monosemanticity: 한 뉴런(특징)이 하나의 해석 가능한 개념에 대응하는 정도.

2. PathoSAEv3 요약 (현재 설계 기준)

PathoSAEv3 는 기존 연구가 주로 Vanilla SAE 1 종만 평가했던 한계를 넘어, 동일 조건에서 4 가지 SAE variant(Vanilla, Gated, TopK, JumpReLU)를 공정 비교하여 ‘어떤 SAE 가 병리 해석가능성에 최적인가?’를 답하려는 실험 프레임워크이다.

2.1 입력 표현과 데이터 형태

Backbone: EXAONEPath (ViT-B/16)에서 layer 12 의 출력 토큰을 사용한다.

- 입력 타일: 224×224
- 패치 크기: $16 \times 16 \rightarrow 14 \times 14 = 196$ spatial tokens
- 토큰 차원: 768
- 학습 샘플: 토큰 단위로 flatten 하여 ($N \times 196$, 768) 형태로 SAE 에 입력 (대규모 패치 수)

2.2 SAE variant (비교 대상 4 종)

Variant	Activation	Sparsity 제어	핵심 관점
Vanilla	ReLU(pre_act)	L1 penalty(간접)	기준선(baseline)
Gated	ReLU(pre_act) $\times$ Gate	L1 + gate	선택적 활성화(이진 게이트)
TopK	TopK(pre_act, k)	k 로 직접 제어	희소성 일정(예측 가능)
JumpReLU	pre_act $\times$ H(pre_act - θ)	L0 penalty(뉴런 수)	뉴런별 적응 임계값

2.3 통일된 학습 프로토콜(공정 비교 원칙)

PathoSAEv3 의 핵심은 ‘variant 별 하이퍼파라미터를 통일하고, activation/sparsity 메커니즘만 다르게’ 하여 비교한다는 점이다.

- 입력 dim=768, latent dim=24,576($32 \times$ expansion)
- epochs=10, batch size=4,096, lr=3e-4
- warmup + cosine decay, sparsity warmup(초기 재구성 우선)
- float32 고정(AMP/정밀도 차이로 인한 공정성 훼손 방지)

2.4 PathoSAEv3 에서 이미 계획된 기본 지표

Metric	정의(요약)	의미
MSE	$\text{mean}((x - x_{\text{hat}})^2)$	재구성 품질
FVU	$\Sigma(x - x_{\text{hat}})^2 / \Sigma(x - \mu)^2$	설명되지 않은 분산 비율
Cosine Similarity	$\text{mean}(\cos(x, x_{\text{hat}}))$	방향/구조 보존
L0	$\text{mean}(\text{count}(z > 0))$	샘플당 평균 활성화 뉴런 수
Sparsity	$\text{mean}(z == 0)$	0 의 비율
Active/Dead Neurons	활성 여부 집계	dictionary 사용 효율/죽은 뉴런 점검

3. 평가 목표를 6 가지로 분해

SAE 평가를 한두 개 수치로 끝내면 ‘해석가능하다’는 주장에 약점이 생긴다. 따라서 PathoSAEv3에서는 평가 목표를 아래 6 개 축으로 분해하고, 각 축마다 최소 1 개 이상의 정량 지표 + 1 개 이상의 시각화 산출물을 갖추는 것을 권장한다.

평가 축	핵심 질문
G1. 재구성 충실도	SAE 가 원래 임베딩을 충분히 보존하는가? (해석성이 성능을 망치지 않는가)
G2. 희소성/사전(dictionary) 효율	희소성은 충분한가? dead neuron 이 많은가? sparse 제어가 안정적인가?
G3. 개념 일관성/단의미성	한 뉴런이 하나의 형태학적 개념으로 보이는가? polysemantic 인가?
G4. 인과적/충실도 기반 설명	뉴런을 조작했을 때 다운스트림 판단이 실제로 바뀌는가? (faithfulness)
G5. 일반화/강건성/편향	스캐너/염색/기관 차이, 도메인 시프트에서도 개념이 유지되는가?
G6. 임상적 유용성과 의학적 증빙	개념이 진단/예후/서브타입 분류 등 임상 문제에 실제로 도움이 되는가?

3.1 논문별로 어느 축을 강조하는가

첨부 논문 3 편이 주로 다루는 축을 간단히 매핑하면 아래와 같다.

논문	주요 축	핵심 지표/테스트	PathoSAEv3 도입 포인트
CytoSAE	G2, G3, G6	개념 시각화, 패치/환자 바코드, 분류 성능(가중 F1 등)	슬라이드/환자 단위 ‘concept barcode’ + 분류/차별 특징
Pathology SAE Utility (PLUTO)	G3, G5, (G2)	HIF 상관+엔트로피 단의미성, universality, 스캐너/염색 robustness, sparse probe R2	HIF 기반 단의미성/보편성 평가 + confounder 점검
VLM SAE Monosemanticity	G3, (G2)	MS(activation-weighted similarity) + 인간 정렬(user study)	패치 집합 기반 단의미성 정량화(사람 평가 포함)

4. (공통) 재구성/희소성/안정성 지표

이 섹션은 'SAE 자체의 품질'을 보는 공통 지표들이다. PathoSAEv3 는 variant 비교 논문이므로, 아래 지표는 4 개 모델 모두에 대해 동일하게 계산되어야 한다.

4.1 재구성 품질 (Reconstruction Fidelity)

권장 지표:

- MSE: 임베딩 재구성 오차의 가장 기본 지표
- FVU(Fraction of Variance Unexplained): 데이터 분산 대비 재구성 실패 비율
- $R^2 (= 1 - FVU)$: VLM 논문에서도 reconstruction quality 를 R^2 로 보고(해석하기 쉬움)
- Cosine Similarity: 임베딩 방향 보존(클러스터 구조 보존)을 간단히 체크

권장 산출물:

- 학습 step/epoch 에 따른 MSE/FVU 곡선(variant 4 개를 같은 plot 에)
- 재구성 오차의 분포(histogram)와 outlier 비율

4.2 희소성 및 dictionary 효율 (Sparsity & Utilization)

SAE 의 핵심은 '희소한 활성화로 많은 개념을 분해'하는 것이다. 따라서 L0/L1 만 보고 끝내지 말고, dictionary 가 실제로 얼마나 '쓰이는지'까지 함께 보고해야 한다.

- L0(샘플당 활성 뉴런 수), sparsity(0 비율): variant 비교의 핵심 축
- Active neurons: 평가 데이터에서 한 번이라도 활성화된 뉴런 수
- Dead neurons: 완전히 비활성인 뉴런 수(너무 많으면 용량 낭비/학습 문제 가능)
- Activation histogram(뉴런별 평균 활성/분산): 특정 variant 가 극단적으로 쏠리는지 확인

4.3 안정성/재현성 (Stability & Reproducibility)

논문에서 해석가능성 주장은 '재현 가능성'이 특히 중요하다. PLUTO 논문은 seed 가 다른 SAE 10 개에서 단 의미성 분포가 일관됨을 보여준다.

- Seed 반복 학습(최소 3 회, 가능하면 5 회): 각 지표의 평균±표준편차 보고
- 같은 concept 이 seed 가 바뀌어도 반복적으로 등장하는지(보편성/유니버설리티) 확인
- 데이터 샘플링/전처리 변화(색상 정규화 등)에 대한 민감도 체크

4.4 PathoSAEv3 코드에 바로 반영하는 방법(큰그림)

현재 pathoSAEv3.md 에 evaluation/metrics.py 가 존재하므로, 아래를 확장하는 형태가 자연스럽다.

13. results/{run_name}/metrics.json 에 (MSE, FVU, R^2 , Cosine, L0, sparsity, active/dead) 표준 스키마로 저장
14. compare.py 에서 모든 variant(그리고 seed 반복)의 평균±표준편차를 집계해 comparison_table.csv 생성

15. mse_vs_l0.png(Pareto) 외에, R2_vs_L0, ActiveNeurons_vs_MSE 같은 보조 Pareto 도 자동 생성

4.5 구현 스니펫(의사코드)

```
# x: [B, d] input token embeddings
# x_hat: reconstructed embeddings
mse = ((x - x_hat) ** 2).mean()

# FVU and R2
var = ((x - x.mean(dim=0)) ** 2).sum()
res = ((x - x_hat) ** 2).sum()
fvu = res / (var + 1e-8)
r2 = 1.0 - fvu

# sparsity
l0 = (acts > 0).float().sum(dim=1).mean() # avg active neurons per sample
sparsity = (acts == 0).float().mean()
```

5. 논문 A - CytoSAE 에서 가져올 수 있는 지표와 테스트

CytoSAE 는 혈액학 단일세포 이미지에서 foundation model 임베딩을 SAE 로 분해하고, ‘개념 (concept)’을 환자/질환 단위로 집계하여 실제 질병 분류까지 연결한다. PathoSAEv3 는 도메인이 조직 병리 이지만, ‘개념을 집계해 임상적 판별력을 보인다’는 구조를 그대로 가져올 수 있다.

5.1 CytoSAE 가 사용하는 핵심 평가 아이디어

- SAE latent 을 형태학적 ‘개념 사전(dictionary)’로 해석하고, 각 개념을 top-activating 패치로 시각화
- Patch-level attribution/segmentation: latent 활성화로 공간 지도를 만들어 ‘어디가 그 개념인지’ 보여줌
- Patient barcode: 환자별로 각 개념이 얼마나 자주/강하게 활성화되는지 집계해 바코드 벡터 생성
- Barcode 로 간단한 분류기(logistic regression)를 학습해 질환 예측 성능을 정량화(가중 F1 등)
- 활성화 임계값(threshold)을 바꿔 ‘의미 있는 개념만 남겨도 성능이 유지/개선되는가’를 테스트
- 전문가가 top concept 을 보고 실제 질환 특이 형태학인지 판정(질적 + 일부 정량)




Fig. 1. Overview. (A) CytoSAE is trained on over 40K peripheral blood single-cell images using embeddings from DinoBloom-B, disentangling compact embedding information into meaningful concepts. We employ MSE loss for embedding reconstruction and apply L1 normalization to SAE latents. (B) Patient-level information is aggregated by counting the number of activations for each concept within the patient’s single-cell images, forming a “barcode”. This analysis is extended to the disease level to identify disease-specific morphological concepts.

enforcing sparsity in its latent representation through an L1 norm regularizer [4],

$$\min_{W_{enc}, b_{enc}, W_{dec}, b_{dec}} \sum_{i=1}^K (\|x_i - \hat{x}_i\|_2^2 + \lambda \|f(x_i)\|_1), \quad (1)$$

for tokens $x_1, \dots, x_K$ generated by the backbone model. We center the input by subtracting the decoder bias b_{dec} initialized with the geometric median of the training tokens. We use ghost gradient resampling [4] to limit unused latents.

Training and validation. We obtained tokens from DinoBloom-B [14], a hematology foundation model that partitions images into 14×14 sized patches. It processes 257 tokens, including the CLS token, each with a dimension of 768. For the SAE, we expanded this dimension by a factor of 64 and arrived at a 49,152 dimensional latent space. Among various options for backbone model representations to decompose, we used the residual stream output from the second last attention layer. After feeding cell images into DinoBloom-B, we extracted the residual layer output and passed it to the SAE. During model development, we performed an ablation study on the hyperparameters and choose the value highlighted with *: expansion factor [16, 32, 64*, 128], b_{dec} initialization method [mean, geometric median*], residual output layer [2, 5, 11*, 12], ghost gradient resampling [True*, False], L1 coefficient [8×10^{-4} , 8×10^{-5} *, 8×10^{-6}], and learning rate [4×10^{-3} , 4×10^{-4} *, 4×10^{-5}] with a constant warmup schedule (500 warmup steps). We used MSE, L1, and L0 loss to measure training performance. Each experiment was repeated three times with different random seeds.

We trained CytoSAE on the MLL23 dataset [25], which includes 41,906 peripheral blood single-cell images from 18 different cell types (Fig. 1A). The dataset includes blood cells at various maturation stages and abnormalities from

그림 A1. CytoSAE Figure 1(개념 사전 + 환자 바코드 개요).




Fig. 4. Patient-wise concepts can predict disease. (A) We train a logistic regression classifier on patient barcodes, varying the number of latents; latents above the threshold were used in classification, with others set to zero. (B) Multi-class classification performance of logistic regression using patient barcodes is comparable to a fully deep learning approach [12].

patients with the same disease, we created disease barcodes (Fig. 1B, Eq. 3). This approach enabled both patient-wise comparisons and disease classification while identifying morphological concepts uniquely expressed in individual patients. To evaluate the discriminative power of these morphological concepts, we performed disease classification using patient barcodes while varying the number of latents included in the classification (Fig. 4A). Although adjusting the threshold from -6 to 0 ($\log_{10}$) reduced the number of latents used in classification (Fig. 2A), classification performance remained stable up to a certain threshold and using only meaningful concepts resulted in higher classification performance (Fig. 4A). Our findings confirm that classification performance is only affected when meaningful concepts are removed. Multi-class classification at a threshold of -3 ($\log_{10}$) achieved a weighted F1-score of 0.832 ± 0.044 which is similar to the performance of fully deep learning baseline [12]. By comparing disease barcodes, we identified the top-100 latents that were differentially expressed between the *CBFB::MYH11* and *PML::RARA* subtypes (50 for each disease). Experts annotated these concepts and assessed whether they represented disease-specific morphological features recognizable by a cytomorphologist. Among the top features, 5 out of 10 and 32 out of 50 were identified as *CBFB::MYH11*-specific, while 4 out of 10 and 10 out of 50 were classified as *PML::RARA*-specific. *CBFB::MYH11*-specific concepts predominantly highlighted large monocytic precursors with segmented nuclei and cytoplasmic vacuoles (Fig. 5B). In contrast, *PML::RARA*-specific concepts were characterized by granulated blasts and morphological features suggestive of anemia (Fig. 5B).

그림 A2. CytoSAE Figure 4(활성 임계값에 따른 barcode 분류 성능, 혼동행렬).

5.2 PathoSAEv3 에 도입 가능한 지표/실험

CytoSAE 의 평가를 PathoSAEv3 로 옮기면 아래 3 단계 실험으로 정리된다.

5.2.1 (개념 시각화) Top-activating patches & concept card

각 latent i 에 대해 activation 이 큰 패치 상위 K 개(예: $K=32$)를 모아 'concept card'를 만든다. 이것은 가장 직관적인 해석가능성 증거이며, PLUTO 논문에서도 Figure 1/2에서 동일한 접근을 사용한다.

- 정량 보조지표: top- K 패치 집합의 '내부 일관성'(Section 8에서 제안하는 coherence score)
- variant 비교: 같은 K 에서 concept card의 질(전문가 평가/정량 점수)이 어느 variant가 높은가?

5.2.2 (공간적 증거) 패치 활성화 기반 heatmap/segmentation

PathoSAEv3는 196 spatial tokens을 사용하므로, 각 tile(224×224) 내부에서 14×14 패치별 latent activation을 바로 heatmap으로 만들 수 있다. CytoSAE는 패치에 latent 활성화값을 곱해 개념을 시각화한다.

- 산출물: (원본 타일) + (latent i heatmap overlay) + (top patches) 3종 세트
- 가능하다면: tumor/immune region 등 GT 마스크가 있는 데이터에서는 IoU/pointing game 같은 정량 localization 지표로 확장

5.2.3 (임상 연결) 슬라이드/환자 concept barcode + 분류 성능

CytoSAE의 핵심은 '개념을 집계해서 진단 문제에 연결'하는 것이다. PathoSAEv3에서도 WSI/환자 단위 라벨(암종/등급/서브타입 등)이 있다면 거의 동일하게 구성할 수 있다.

16. 각 패치 샘플(또는 tile)에서 SAE activation z 를 계산
17. 환자 p 에 대해 모든 패치의 activation을 집계해 barcode b_p 생성
18. 집계 방법 예시: (1) activation $> \tau$ 인 횟수(count), (2) activation 합(sum), (3) 상위 $q\%$ 만 합(trimmed sum)
19. b_p 를 입력으로 logistic regression / linear SVM / simple MLP를 학습해 라벨 예측
20. 성능 지표: AUROC(이진), macro/micro F1, weighted F1, balanced accuracy, sensitivity/specificity
21. 특히 '활성 임계값 τ 또는 사용 latent 개수'를 바꿔도 성능이 유지되는 구간이 있는지 확인 → '의미 있는 개념만으로도 충분' 주장 가능

5.3 PathoSAEv3 구현 포인트

- 데이터에 patient_id/slide_id 메타데이터를 반드시 붙여서 activation을 집계할 수 있게 한다
- results/ 아래에 (1) concept_cards/, (2) heatmaps/, (3) barcodes.csv, (4) barcode_classifier_metrics.json 자동 저장
- 실험 공정성을 위해 4개 variant 모두 같은 threshold grid(예: τ in logspace)로 sweep

5.4 구현 스니펫(의사코드)

```
# acts: [num_patches, n_latents] for one patient/slide
# threshold tau can be chosen globally or per-latent
binary = (acts > tau).float()
```

```
barcode_count = binary.sum(dim=0)    # concept occurrence counts
barcode_sum  = acts.clamp(min=0).sum(dim=0)

# Optional: normalize by number of patches
barcode = barcode_count / (acts.shape[0] + 1e-8)

# Train a simple classifier
# X: [num_patients, n_latents], y: labels
clf = LogisticRegression(max_iter=1000)
clf.fit(X_train, y_train)
pred = clf.predict_proba(X_test)[:, 1]
```

6. 논문 B - Pathology FM SAE Utility(PLUTO-SAE)에서 가져올 수 있는 지표와 테스트

이 논문은 ‘병리 파운데이션 모델 임베딩에 SAE 를 붙였을 때 해석가능성이 정말로 증가하는가?’를 정량적으로 평가하기 위한 프레임워크를 제안한다. 특히 (1) HIF 기반 단의미성(엔트로피), (2) sparse probe 예측력 (R2), (3) universality, (4) 스캐너/염색 confounder robustness 같은 ‘의학 논문에서 설득력 있는 근거’가 많아 PathoSAEv3 에 가장 직접적으로 유용하다.

6.1 PLUTO 논문의 평가 구성 요소

요소	무엇을 보나	왜 중요한가(논문 설득력)
Feature visualization	각 SAE 뉴런의 top-activating patch 를 모아 사람이 해석	해석가능성의 1 차 증거(직관)
UMAP+HDBSCAN clustering	SAE 뉴런들을 클러스터링하고 클러스터 의미를 부여	dictionary 가 ‘구조화된’ 개념 공간인지 증명
HIF correlation	뉴런 활성과 세포 수/핵 특징 등 HIF 의 상관(ρ)	뉴런이 실제 생물학적 변수와 연결됨을 정량화
Monosemanticity entropy	각 뉴런이 여러 HIF 중 하나에 특이적으로 반응하는지(엔트로피)	단의미성의 핵심 정량 지표
Universality	독립적으로 학습된 SAE 에서 같은 feature 가 반복적으로 발견되는지	우연/seed 의존이 아니라 ‘진짜 개념’일 가능성 $\uparrow$
Robustness to stain/scanner	특정 뉴런이 염색/스캐너를 예측하지 못하는지(AUROC $\approx$ 0.5)	의학적 증빙에서 confounder 배제 매우 중요
Sparse probe	k 개 뉴런만으로 HIF 를 예측하는 선형 모델의 R2	dictionary 가 ‘효율적으로’ 정보를 담는지(실용성)




Figure 2: UMAP of 3072 SAE dimensions from the IM model. Feature clusters are identified by HDBSCAN and are interpreted by manual inspection. Several clusters clearly associated with histological concepts are highlighted. For cancer and immune cell clusters, visualizations of top 3 patches that maximally activate the SAE dimension are shown.




Figure 3: Pearson correlations of SAE dimensions of PLUTO and DINO models with counts of pathology-relevant cell types, showing much higher correlations of the PLUTO SAE dimensions with the cell count features.

We choose the same input patch size as PLUTO and SAE training methodology as in Section 2 to ensure a fair comparison.

To evaluate these two models, we extract human-interpretable features (HIFs) [19] quantifying the counts of cancer cells, plasma cells, lymphocytes, macrophages, and fibroblasts (Section 2.4), and correlate these features against dimensions in the SAE latents of the two models. We find SAE dimensions in PLUTO that strongly correlate with cell counts: plasma cells ($\rho = 0.7$), lymphocytes ($\rho = 0.63$), cancer cells ($\rho = 0.37$), macrophages ($\rho = 0.38$), and fibroblasts ($\rho = 0.21$). In contrast, SAE dimensions of DINO show weak association with these cell count features (Figure 3).

3.3 A small proportion of SAE features are universal

Previous work suggests that SAE dimensions are more likely to be useful (representing true monosemantic features in the real world) if they display *universality* (the same feature is discovered across independently trained SAE models [5]). We examine feature universality by comparing the SAE activations from the two independently trained SAE models (TCGA and IM). We define “universality” as pairs of SAE features with Pearson’s ρ above 0.5, where the correlation is computed between the activation of those two features across all images in the TCGA dataset. Using the Hungarian matching algorithm, we identify 5% (152) SAE dimensions exhibiting feature universality between

그림 B1. PLUTO-SAE Utility Figure 2(UMAP+HDBSCAN 클러스터)와 Figure 3(HIF 상관 비교).




Figure 4: SAE features are more monosemantic than the FM features they are trained on. A) Entropy distribution of PLUTO embedding dimensions (left, gray box), and the embedding dimensions of the 10 independently trained SAEs (right, light green boxes). B) Number of monosemantic dimensions for each HIF in the SAE latent space (red), or PLUTO embedding space (black). Note that count of monosemantic dimensions for PLUTO is zero for 7/8 features.




Figure 5: Monosemanticity emerges in later layers of PLUTO. A) SAE dimensions with the highest correlation with each cell count features across layers. B) Correlation of color features with SAE dimensions.

embedding on which it is trained, suggesting that the SAE transforms the highly polysemantic original embeddings into a space with higher monosemanticity.

We investigate SAE-1736 as an illustration of a monosemantic dimension in the SAE latent space. SAE-1736 highly correlates with plasma cell counts ($\rho = 0.70$) while showing minimal correlation ($\rho < 0.1$) with other cell types, suggesting high specificity of the activation. In contrast, no such monosemantic plasma cell feature is found in the PLUTO embedding space. The strongest plasma cell-associated PLUTO dimension, 148 ($\rho = 0.29$) also correlates with counts of other cell types.

4.2 Monosemanticity in SAE features emerges in later layers of the FM

We investigate how monosemanticity of SAEs evolves across layers by measuring the monosemanticity of SAE latent dimensions for models trained on CLS tokens from different layers of PLUTO. In earlier layers, SAE dimensions correlate with low-level color features such as intensity, hue and saturation (Figure 5B). Correlations of these SAE dimensions with cellular features are low ($\rho < 0.5$ for lymphocytes and $\rho < 0.3$ for the other four cell types). At later layers, association of SAE dimensions with color features decreases, while association with cell features increases (Figure 5A). The increase in association with cell type is robust across 10 independently trained SAEs with different random seeds. Furthermore, SAE neurons with low entropy ($S < 0.6$) start to emerge in layers 11 and 12 of the model.

4.3 Monosemantic behavior of SAEs generalizes to new datasets with unseen cancer types

We verify that our results in sections 4.1 and 4.2 generalize to an independent dataset. We extract FM embeddings and deploy the 10 trained SAEs on the CPTAC dataset, which includes two cancer types not included in TCGA (see Methods section 2.1). We confirm that (1) there are more monosemantic

그림 B2. Figure 4(엔트로피 기반 단의미성)와 Figure 5(레이어별 단의미성 등장).




Figure 6: Illustration of all monosemantic SAE dimensions of the 1M model, and their correlations with 8 human-interpretable features. Stars indicate the features with the highest correlation for each dimension. Multiple monosemantic SAEs (1574, 1736, 2525 and 2873) can be seen correlating with plasma cell counts.




Figure 7: Performance of sparse probes trained on SAE latent embeddings is not always better than those trained on FM embeddings. A-B) Test R^2 of probes for predicting count of plasma and count of cancer from the SAE latent space (red), or the FM embeddings (black). Probes trained on SAE latents achieve higher test R^2 for predicting plasma counts, but not cancer cell counts. C) Sparse probe test R^2 for all 8 human-interpretable features for $k = 3$.

dimensions from the 10 independently trained SAEs than from the FM embeddings, and (2) neurons in the SAE latent space also correlate with cell count features, particularly in SAEs trained on embeddings from the later layers of the FM.

4.4 Partial monosemanticity limits SAE utility

Our results in Figure 4B suggests that not all interpretable features have an associated monosemantic SAE dimension. We perform a further investigation by analyzing the monosemantic SAE units of the 1M model and the human interpretable features they best correlate with (Fig 6). We find 4 features with associated monosemantic neurons (count of cancer, count of fibroblast, count of macrophage, mean nucleus orientation), and 3 features that do not correlate with any monosemantic SAE neurons (mean nucleus area, mean nucleus eccentricity, count of lymphocyte). Notably, plasma cell counts is correlated with multiple monosemantic SAE units, suggesting potential feature splitting. These results point to a key limitation of SAEs since the monosemantic SAE units don't have a one-to-one mapping with the HIFs.

4.5 SAE sparse probes have mixed performance as compared to FM embeddings

As an orthogonal approach for evaluating the utility of SAE in interpretability analyses, we use k -sparse probes (see Methods section 2.4) to quantify how well a small number of dimensions in SAEs (or dimensions in the original FM embedding space) can be used to predict the 8 HIFs (Fig 7). We find mixed evidence regarding the utility of the SAE latent space, as SAE embeddings show better performance than the FM embeddings in only 4/8 probes. These findings are consistent with a recent study that investigated SAE utility in large language models [42].

그림 B3. Figure 6(단의미성 뉴런- HIF 상관 히트맵)과 Figure 7(k -sparse probe R^2).

6.2 핵심 지표 1: HIF 기반 단의미성(Entropy) - ‘뉴런 1 개=개념 1 개’의 정량화

PLUTO 논문은 N 개의 HIF(예: 세포 type 별 count 5 개 + 핵 특징 3 개)를 준비하고, 각 뉴런의 활성화와 HIF 들 사이의 Pearson 상관(ρ)을 계산한다. 그 다음 $|\rho|$ 를 정규화해 확률분포 p 로 만들고, 그 엔트로피를 monosemanticity 의 역지표로 사용한다.

```
# neuron j, HIF k in {1..N}
rho_jk = corr(act_j, hif_k)      # Pearson correlation
p_jk = abs(rho_jk) / sum_k abs(rho_jk)
entropy_j = - sum_k p_jk * log(p_jk + 1e-12)

# entropy_j 가 낮을수록(분포가 뾰족할수록) monosemantic
```

논문에서는 엔트로피 분포에서 ‘낮은 엔트로피의 long tail’이 SAE 에서만 나타나고, 원래 FM 임베딩 차원에 서는 거의 나타나지 않는다는 것을 보여준다.

6.3 PathoSAEv3 에 도입하려면: HIF 를 무엇으로 만들 것인가?

가장 큰 실무 포인트는 ‘HIF 를 어떤 방식으로 생성할지’이다. PLUTO 논문은 PathExplore 로 세포/핵 HIF 를 계산했다. PathoSAEv3 에서는 아래 3 단계 중 가능한 수준을 선택할 수 있다.

- Level 1(최소): 색상/조직학적 기본 통계(H&E intensity, hematoxylin/eosin channel stats, 텍스처) 만으로도 ‘저수준 vs 고수준’ 분리를 볼 수 있음
- Level 2(권장): 셀 검출/분할 기반 HIF(암세포/림프구/대식세포 등 count, 핵 면적/원형도/방향 등) - PLUTO 논문과 직접 비교 가능
- Level 3(확장): 공간적 조직 구조(Haralick texture, gland/cribriform 패턴 score, necrosis score 등) 까지 포함하면 ‘임상적 형태학’에 더 가까워짐

6.4 핵심 지표 2: k-sparse probe - ‘작은 뉴런 집합으로 개념을 예측할 수 있는가’

Sparse probe 는 각 HIF 를 예측하는 선형 회귀/로지스틱 모델을 만들되, 입력 차원을 k 개만 선택(가장 상관 이 큰 k 개 뉴런)해서 학습한다. 평가는 regression 이면 R2, classification 이면 AUROC/F1 등으로 한다.

```
# For each HIF:
# 1) compute corr for each neuron -> pick top-k
topk_neurons = argsort(abs(corr))[0:k]

# 2) fit linear regression on those k dims
reg.fit(Z_train[:, topk_neurons], y_train_hif)
pred = reg.predict(Z_test[:, topk_neurons])
r2 = r2_score(y_test_hif, pred)
```

PLUTO 논문은 SAE latent probe 가 항상 원래 FM 임베딩 probe 보다 좋은 것은 아니며(혼합된 결과), 따라서 ‘단의미성 증가=곧바로 유틸리티 증가’가 아님을 지적한다. PathoSAEv3 에서도 이 결과를 그대로 수용하 고, ‘어떤 variant 가 어떤 HIF 에서 유리한지’를 비교하는 것이 자연스럽다.

6.5 핵심 지표 3: Universality - seed 에 덜 민감한 '진짜 특징' 찾기

Universality 는 (서로 다른 seed 로 학습한) SAE A 와 SAE B 에서 '같은 특징이 재발견되는가'를 보는 지표이다. PLUTO 논문은 동일 데이터에 대해 두 SAE 의 뉴런 활성 벡터를 상관계수로 비교하고, Hungarian matching 으로 1:1 대응을 만든 뒤, $p > 0.5$ 같은 임계값을 넘는 뉴런 쌍 비율을 보고한다.

- PathoSAEv3 적용: variant 내부(seed 3~5 회)에서 universality 를 측정 → 안정성 비교
- 추가로 variant 간에도 '공통으로 발견되는 특징'이 있는지 측정 → variant 간 공통 dictionary/특이 dictionary 분석

6.6 핵심 지표 4: Stain/Scanner Robustness - 의학 논문에서 매우 강력한 방어막

병리 모델은 염색/스캐너 차이에 민감할 수 있고, 잘못하면 '질병'이 아니라 '기관/스캐너'를 학습한다. PLUTO 논문은 특정 세포 type 과 연관된 SAE 뉴런이 스캐너/염색을 예측할 수 있는지 로지스틱 회귀를 학습해 AUROC 로 평가했고, AUROC 가 0.5 근처면 confounder 정보가 선형적으로 회수되지 않는다고 해석한다.

- PathoSAEv3 적용: 병원/스캐너/염색 메타가 있다면 반드시 수행(가능하면 1 개 표(Table)로 제시)
- 방법: (뉴런 활성 1 차원 또는 소수 차원) → confounder 라벨 예측 로지스틱 회귀 → AUROC
- 주의: AUROC ≈ 0.5 가 '완전한 독립'을 의미하지는 않으므로, 비선형 probe(작은 MLP)도 추가하면 더 강함(Section 8)

6.7 PathoSAEv3 실험 설계 제안(PLUTO 지표 중심)

22. HIF 파이프라인 구축(최소 색상 통계, 권장 세포/핵 HIF)
23. 각 variant(그리고 seed 반복)에서: (i) correlation matrix, (ii) entropy distribution, (iii) monosemantic neuron count($S < th$)
24. k-sparse probe 를 $k=\{1,3,5,10\}$ 등으로 sweep 하여 R^2 /AUROC 곡선 생성
25. universality: seed 간 matching 비율($p > 0.5$) 보고 + universal neuron 의 concept card 제시
26. robustness: confounder 예측 AUROC 표로 보고

7. 논문 C - VLM SAE Monosemanticity(MS 지표)에서 가져올 수 있는 지표와 테스트

이 논문은 VLM(CLIP 등)에서 SAE 뉴런의 단의미성을 ‘뉴런 수준(neuron-level)’에서 정량화하기 위해 MonoSemanticity score(MS)를 제안한다. 병리 도메인에 그대로 적용하기 위해서는 ‘사람 인지와 유사한 similarity’를 주는 보조 인코더를 정하는 것이 핵심이다.




Figure 2: Computation of our MonoSemanticity score (MS). (a) Embeddings and activations are extracted for a set of images (b) to compute the pairwise embedding similarities and pairwise neuron activations. (c) MS is the average of embedding similarities weighted by the neuron activations.

and insights from Matryoshka representation learning [34] for SAEs [9, 39]. We analyze and evaluate neuron-level monosemanticity of SAEs in VLMs and their downstream uses.

Vision-Language Models. Since Contrastive Language–Image Pretraining (CLIP) [38, 47, 61], many models have emerged that align images and text in a shared embedding space [32, 56] or generate text conditioned on image inputs [12, 19, 36]. They have achieved strong results on benchmarks [59] and found many use-cases [5, 24, 26, 28]. As trust in these models has become a concern [4, 27, 60], understanding decision-making and ensuring safety, for example through steering, is increasingly important [2, 29]. Consequently, prior work has examined their internal representations [21, 22, 40, 45], uncovering interpretable neurons [15]. We demonstrate that SAEs enable more effective interpretation and control than directly operating on raw features.

SAEs for VLMs. Building on the success of SAEs in interpreting LLMs, researchers have tried applying them to vision and vision-language models, typically on CLIP [20, 35, 49, 50] and other vision encoders (e.g. DINOv2 [44]). There has also been interest in interpreting the denoising diffusion models [25] using SAEs [11, 30, 31, 51], discovering common concepts across different vision encoders [53], and applying them on multimodal LLMs [63]. Concurrently, monosemanticity of multimodal models has been investigated [58], although focusing on inter-modality differences. Our MS score provides a grounded, quantitative measure of the monosemanticity of individual neurons which is empirically aligned with human perception. Overall, we create a rigorous evaluation framework for SAEs in VLMs, as well as demonstrating their use for steering multimodal LLMs.

3 Sparse Autoencoders for VLMs

3.1 Background and Formulation of SAEs

SAEs implement a form of sparse dictionary learning, where the goal is to learn a sparse decomposition of a signal into an overcomplete dictionary of atoms [42]. More specifically, an SAE consists of linear layers $\mathbf{W}_{\text{enc}} \in \mathbb{R}^{d \times \omega}$ and $\mathbf{W}_{\text{dec}} \in \mathbb{R}^{\omega \times d}$ as *encoder* and *decoder*, with a non-linear activation function $\sigma : \mathbb{R}^{\omega} \rightarrow \mathbb{R}^{\omega}$. Both layers share a bias term $\mathbf{b} \in \mathbb{R}^d$ subtracted from the encoder’s input and later added to the decoder’s output. The *width* ω of the latent SAE layer is chosen as a factor of the original dimension, such that $\omega := d \times \varepsilon$, where ε is called the *expansion factor*.

In general, SAEs are applied on embeddings $\mathbf{v} \in \mathbb{R}^d$ of a given layer l of the model to explain $f : \mathbb{X} \rightarrow \mathbb{Y}$, such that $f_l : \mathbb{X} \rightarrow \mathbb{R}^d$ represents the composition of the first l layers and $\mathbb{X} \subset \mathbb{R}^{d_l}$ is the space of input images. A given input image $\mathbf{x} \in \mathbb{X}$ is first transformed into the corresponding embedding vector $\mathbf{v} := f_l(\mathbf{x})$, before being decomposed by the SAE into a vector of activations $\phi(\mathbf{v}) \in \mathbb{R}^{\omega}$, and its reconstruction vector $\hat{\mathbf{v}} \in \mathbb{R}^d$ is obtained by:

그림 C1. VLM 논문 Figure 2: MonoSemanticity score(MS) 계산 개요(activation-weighted similarity).

per image, taken from layer $l = 22$. For other encoders, we similarly use the CLS tokens from the final layers, or two random token embeddings if a CLS token is not available.

In the following sections, we are interested in both BatchTopK [8] and Matryoshka BatchTopK SAEs [9] variants. If not stated otherwise, we set the groups of Matryoshka SAEs as $\mathcal{M} = \{0.0625\omega, 0.1875\omega, 0.4375\omega, \omega\}$, which roughly corresponds to doubling the size of the number of neurons added with each level down. For the BatchTopK activation, we fix the maximum number of non-zero latent neurons to $K = 20$. Both SAE types are compared across a wide range of expansion factors $\varepsilon \in \{1, 2, 4, 8, 16, 64\}$. All SAEs are optimized for 10^5 steps with minibatches of size 4096 using Adam optimizer [33], with the learning rate initialized at $\frac{16}{125\sqrt{\omega}}$ following previous work [23]. To measure SAE performance, we use R^2 for reconstruction quality and the L^0 norm for the activation sparsity of $\phi(\mathbf{v})$. Throughout the paper, we quantify MS of neurons using DINOv2 ViT-B [44] as image encoder E , and present more analysis with different encoders in Appendix. Experiments are run on a single NVIDIA A100 GPU.

4.2 Evaluating Interpretability of VLM Neurons

4.2.1 Alignment of MS with human perception

We first illustrate the correlation between MS score and the underlying monosemanticity of neurons, with examples in Figure 3 of the 16 highest activating images for neurons with decreasing MS from left to right. We observe that the highest scoring neurons (with MS = 0.9, on the far left) are firing for images representing the same object, i.e. close-up pictures of a *koala* (on the top) and a *hockey* (on the bottom). As the score decreases, the corresponding neurons fire for less similar or even completely different objects or scenes. To verify this observation in a more quantitative way, we conducted a large scale user study on the Mechanical Turk platform. This study resulted in a total of 1000 questions across 71 unique users, with 3 answers per question aggregated through majority voting. Results of this study are presented in Figure 4, and we provide more details on the setup in Appendix. When asked to select the set of more monosemantic images from a pair of sets (a, b) , the users answered in accordance to the MS in 82.8% of the cases, assuming $\delta = |\text{MS}(a) - \text{MS}(b)| \sim \mathcal{U}(0, 0.9)$. This alignment rate monotonically raises from 56.6% for $\delta \in (0.0, 0.1)$ to 100.0% for $\delta \in (0.8, 0.9)$, highlighting that users especially agree with MS as the difference in monosemanticity between the two sets becomes more pronounced. This demonstrates that MS can be used as a reliable measure aligning well with human perception of similarity. Detailed results of the user study are released for future benchmark of image similarity and monosemanticity.




Figure 4: Alignment Rate (AR, %) of humans with MS score when judging which neuron in a pair is more monosemantic, grouped by MS difference between the neurons. Bars show AR per interval; dots show cumulative AR up to that interval.

4.2.2 Monosemanticity of SAEs

In Table 1a, we report MS of the highest scoring neurons of two SAE types (BatchTopK [8] and Matryoshka BatchTopK [9]) trained at different layers with various expansion factors ε . We also include results for original neurons of the corresponding layer decomposed by SAEs (“No SAE”). We observe that SAEs’ neurons consistently have significantly higher MS for their best neuron when compared to original ones, implying that SAEs are better separating and disentangling concepts between their neurons. Interestingly, while the highest MS score is increasing with higher expansion factor ε , i.e. with increased width ω of the SAE layer, this holds true already for expansion factor $\varepsilon = 1$, meaning that the disentanglement of concepts is also linked to the sparse dictionary learning and not only to the increased dimensionality. Finally, comparing SAE variants, we observe that while the Matryoshka reconstruction objective improves the concept separation at same expansion factor, it also achieves about 2 or 3 points lower R^2 for the same expansion factors (more details in Appendix).

7.1 MS 지표의 직관

어떤 뉴런 j 가 ‘단의미적’이라면, 그 뉴런이 강하게 활성화되는 이미지들은 서로 비슷해야 한다. 즉, 뉴런 활성화 (a_j)이 큰 이미지 쌍일수록 이미지 임베딩 유사도(similarity)가 높게 나와야 한다. MS 는 이를 ‘활성 가중 평균 similarity’로 정량화한다.

```
# X = {x_1..x_N} images
# a_n = activation of neuron j on image n (>=0)
# e_n = embedding of x_n from a (separate) image encoder E
# s_nm = cosine_similarity(e_n, e_m)

# one reasonable weighting (paper illustration):
w_nm = a_n * a_m
MS_j = sum_{n<m} w_nm * s_nm / (sum_{n<m} w_nm + 1e-12)
```

7.2 PathoSAEv3 에 MS 를 도입할 때의 핵심 결정 2 가지

- 결정 1) similarity 를 계산할 ‘보조 인코더 E’ 선택: EXAONEPath 와 동일 임베딩을 쓰면 자가증명 위험 (트리비얼) → 가능하면 다른 자기지도/대조학습 인코더를 사용
- 결정 2) 샘플링: PathoSAEv3 는 패치 수가 매우 크므로, MS 는 전체 패치가 아니라 대표 샘플(예: 50k~200k 패치)로 계산

7.3 Pathology 버전 MS 설계안

병리에서는 ‘시각적 유사도=조직학적 유사도’가 되도록 E 를 선택하는 것이 중요하다.

- Option A(현실적/빠름): DINOv2 같은 범용 비지도 비전 인코더로 patch embedding 을 만들고 similarity 계산
- Option B(권장): 병리 특화 self-supervised 인코더(가능하면 외부 공개 모델)를 사용 → 조직학적 유사도에 더 근접
- Option C(최상): PathoSAEv3 데이터에서 별도 contrastive 학습으로 ‘perceptual encoder’를 만든 뒤 사용

MS 의 해석: MS 가 높을수록 ‘그 뉴런이 켜질 때 나오는 패치들이 한 덩어리의 시각적(조직학적) 개념으로 묶인다’는 뜻이다. 즉, PLUTO 의 엔트로피 기반 단의미성과는 다른 축(‘HIF 없이도’ 가능)에서 단의미성을 정량화할 수 있다.

7.4 인간 평가(병리학자 리뷰)로 MS 를 검증하는 방법

VLM 논문은 Mechanical Turk 사용자 스터디로 MS 가 사람 판단과 정렬되는지 검증한다. 병리에서는 다음과 같은 ‘경량 병리학자 평가’를 설계할 수 있다.

27. 각 variant 에서 MS 상위 뉴런과 하위 뉴런을 각각 M 개씩 샘플링(예: 상위 20, 하위 20)
28. 각 뉴런마다 top-activating patch 16 개 그리드(=concept card)를 생성

29. 평가 질문: (a) ‘하나의 일관된 형태학적 개념으로 보이는가?’ (Likert 1~5), (b) ‘어떤 개념인가?’(자유기술/라벨), (c) 혼합/애매 여부
30. 두 뉴런 A,B 의 카드 쌍을 보여주고 ‘어느 쪽이 더 단의미적인가?’를 선택하게 하여, MS 차이가 클수록 agreement 가 증가하는지 확인(논문 Figure 4 와 동일 논리)

7.5 PathoSAEv3 구현 포인트

- evaluation/ms_score.py: (1) 샘플 패치 선택, (2) 보조 인코더 E 로 embedding, (3) 뉴런별 MS 계산
- 메모리 최적화: similarity matrix 는 $O(N^2)$ 이므로, N 을 제한하거나 mini-batch 로 누적 계산(또는 random pair sampling)
- variant 비교 산출물: (i) MS 분포 히스토그램, (ii) 상위/하위 뉴런 concept card, (iii) MS vs L0(또는 MSE) trade-off plot

8. 추가 제안: SAE/XAI/Medical 에서 설득력을 높이는 지표 묶음

첨부 논문 지표만으로도 강력하지만, ‘의학적 증빙성’ 관점에서 논문 설득력을 더 높이려면 아래의 보조 지표/테스트를 함께 구성하는 것이 좋다. 특히 병리에서는 confounder, 외부 검증, calibration, 인간 평가, 인과적 충실도(faithfulness)가 자주 공격 지점이 된다.

8.1 (G4) Faithfulness/인과 검증: ‘이 뉴런이 정말로 모델 판단 근거인가?’

SAE 는 post-hoc 해석 도구이기 때문에, ‘그렇듯한 패치’를 보여주는 것만으로는 ‘모델이 그 근거로 판단했다’는 인과 주장이 약하다. 이를 보완하는 표준 접근이 ‘intervention(개입) 테스트’다.

8.1.1 뉴런 삭제(ablations) 테스트

아이디어: 특정 뉴런(또는 뉴런 집합)을 0 으로 만들고 재구성된 임베딩을 downstream 으로 넣었을 때 예측이 얼마나 변하는지 본다.

- 필요 조건: downstream task(예: 슬라이드 레벨 암/정상, 서브타입)가 있어야 함
- 방법: (1) 원래 임베딩 $x \rightarrow$ 분류기 $f(x)$, (2) SAE 로 x_{hat} 만들기, (3) 특정 뉴런만 0 으로 만든 $x_{\text{hat}}(-j) \rightarrow f(x_{\text{hat}}(-j))$
- 지표: Δlogit , Δprob , AUC drop, sensitivity drop
- 강화: 뉴런을 개념 그룹(클러스터) 단위로 ablate 하면 더 해석 가능

8.1.2 뉴런 증폭(amplification) / 방향 개입

Ablation 이 ‘필요성(necessity)’이라면, 특정 뉴런을 인위적으로 키우는 것은 ‘충분성(sufficiency)’을 테스트한다.

- 방법: $z_j \leftarrow z_j + \alpha$ ($\alpha > 0$) 또는 $z_j \leftarrow (1 + \alpha) z_j$
- 주의: 너무 큰 α 는 분포 밖(OOD)로 나갈 수 있으므로 작은 grid 로 sweep
- 지표: 특정 진단 class 확률이 개념적으로 타당한 방향으로 변하는지(예: ‘tumor-like’ 개념 뉴런을 키우면 tumor 확률 증가)

8.1.3 공간 기반 insertion/deletion 테스트(가능하면 강력)

PathoSAEv3 는 spatial token 을 쓰므로, latent activation map 으로 중요한 패치를 선정해 원본 이미지에서 해당 패치만 남기거나 제거한 뒤 모델 성능 변화를 측정할 수 있다.

- Deletion: 가장 중요 패치부터 제거할 때 성능이 빠르게 떨어지면 ‘설명 충실’ 가능성 ↑
- Insertion: 중요 패치만으로도 일정 성능이 나오면 sufficiency 근거
- 지표: deletion/insertion curve 의 AUC, drop@k%

8.2 (G3) Concept 품질을 정량화하는 보조 지표

8.2.1 Concept Coherence Score(제안)

Top-activating 패치 집합의 ‘서로 유사한 정도’를 수치로 만든다. VLM 논문의 MS 와 유사하지만, (1) 보조 인코더 없이도 계산 가능하게 단순화하거나, (2) MS 를 patch-level 로 경량화한 버전으로 사용할 수 있다.

- 방법 A: top-K 패치의 보조 임베딩 e 를 구하고, 평균 pairwise cosine similarity 를 coherence 로 사용
- 방법 B: top-K 를 UMAP 으로 2D 투영 후, 클러스터 밀도/분산으로 coherence 측정
- variant 비교: 평균 coherence 가 높은 variant 가 ‘더 깔끔한 개념’을 만든다고 주장 가능

8.2.2 Feature Splitting / Redundancy 지표

PLUTO 논문은 plasma cell count 가 여러 monosemantic 뉴런에 걸쳐 나타나는 ‘feature splitting’ 가 능력을 언급한다. PathoSAEv3 에서도 특정 형태학이 여러 뉴런으로 쪼개지거나, 반대로 여러 뉴런이 거의 동일한 개념을 잡는 redundancy 가 생길 수 있다.

- 방법: (뉴런-뉴런) activation 상관 행렬에서 high-corr 군집 비율 측정
- 지표: redundancy ratio($p > 0.9$ 인 쌍 비율), effective dictionary size
- 시각화: 상위 200 개 뉴런에 대해 correlation heatmap + 클러스터링

8.3 (G5) 강건성/일반화: 외부 검증과 stress test

의학 논문에서 가장 자주 요구되는 것은 ‘외부 데이터에서 재현되는가’이다. SAE 해석가능성도 마찬가지로 외부 검증이 있으면 신뢰도가 급상승한다.

- 외부 코호트(기관/스캐너/염색이 다른 데이터)에서: (1) monosemanticity(엔트로피/MS) 유지, (2) universality 유지, (3) concept card 가 비슷한 개념으로 보이는지
- Stain augmentation stress test: 강한 색상 변화/블러/압축 artifacts 를 준 뒤 concept 안정성 평가
- 지표: (개념 뉴런의) top-K 패치 교집합(Jaccard), activation 분포 shift(KS test), coherence drop

8.4 (G6) 임상 성능/신뢰성 지표(의학적 증빙)

8.4.1 진단 성능(분류/회귀) + 불확실성/보정(calibration)

SAE 자체는 분류기가 아니지만, ‘concept barcode’나 ‘SAE feature’를 통해 임상 과제를 예측할 수 있음을 보여주면 의학적 유용성이 크게 강화된다. CytoSAE 의 barcode 분류가 대표 사례다.

- 분류: AUROC, AUPRC, sensitivity/specificity, PPV/NPV, macro/weighted F1
- 다중 클래스: macro-F1, balanced accuracy, confusion matrix
- 확률 보정: ECE(expected calibration error), Brier score, reliability diagram
- 임상 의사결정 관점: decision curve analysis(DCA) 또는 net benefit(가능하면)

8.4.2 병리학자 평가 설계(정성→정량)

병리 분야에서 ‘의학적 증빙성’을 가장 직관적으로 강화하는 것은 전문가 평가다. 다만 ‘예쁜 그림 몇 장’이 아니라, 평가 프로토콜을 만들어 정량화해야 한다.

- Concept card 평가: 단의미성(1~5), 임상적 의미(1~5), 아티팩트 여부(yes/no), 해석 난이도(1~5)
- Inter-rater agreement: Cohen’s κ 또는 Krippendorff’s α 로 평가자 간 일치도 보고
- Variant 비교: 동일 뉴런 샘플 수/동일 평가 항목으로 평균 점수와 신뢰구간 비교

8.5 통계적 보고(필수): 신뢰구간과 유의성

의학 논문 심사에서 ‘유의성/불확실성 보고’는 기본이다. 특히 variant 비교는 paired 설정이 많아 적절한 통계가 필요하다.

- 모든 핵심 지표에 대해 95% CI(bootstrap) 제시
- AUC 비교: DeLong test(가능하면) 또는 bootstrap 기반 CI 비교
- monosemanticity entropy 분포 비교: Mann-Whitney U(PLUTO 논문과 동일), multiple comparison 보정(예: BH-FDR)
- seed 반복 결과는 $\text{mean} \pm \text{std} + \text{CI}$ (또는 boxplot)로 보고

9. PathoSAEv3 에 도입하는 전체 실험 설계(권장 최소 세트 + 확장 세트)

이 섹션은 앞에서 제시한 지표들을 ‘논문 실험 섹션’으로 바로 옮길 수 있도록, PathoSAEv3 에서 실제로 어떤 실험 묶음을 돌려야 하는지 패키징한다.

9.1 권장 최소 세트(Minimum Viable Evidence) - 논문 1 차 제출용

리소스/데이터 제약이 있어도 최소한 아래는 갖추는 것을 권장한다. 이 조합만으로도 ‘SAE variant 비교 + 단 의미성 + 임상 연결’ 스토리가 성립한다.

31. 모델 학습: 4 개 variant $\times$ (seed 3 회) = 12 runs (동일 프로토콜)
32. 공통 지표: MSE/FVU/R2/Cosine/L0/sparsity/active/dead (mean $\pm$ std)
33. Pareto: (MSE vs L0), (R2 vs L0) - variant 별 위치 + error bar
34. Concept visualization: variant 별 top concept 20 개 card(고정 규칙으로 선택: 예: 활성 빈도 상위 또는 coherence 상위)
35. HIF-Entropy 단의미성: 최소 HIF 3~8 개로 엔트로피 분포 + monosemantic neuron 비율($S < \text{th}$) 비교
36. Sparse probe: HIF 예측 $R^2(k=\{1,3,5\})$ 비교 (SAE vs 원래 임베딩 baseline 포함)
37. Confounder robustness: stain/scanner/기관 메타가 있으면 AUROC ≈ 0.5 표 1 개로 제시
38. Clinical utility(가능 시): slide/patient barcode 로 한 가지 임상 라벨 분류(AUROC/F1) + threshold sweep

9.2 확장 세트(Strong Evidence) - 리뷰 대응/최종 버전

가능하면 아래를 추가하면 의학적 증빙성과 mechanistic 해석가능성이 크게 강화된다.

39. 외부 코호트(기관/스캐너/염색)에서: entropy/MS/universality 유지 + concept card 비교
40. Universality: seed 간 + (가능하면) 데이터셋 간 matching 비율 보고
41. MS score: 보조 인코더 기반 단의미성 정량화 + 병리학자(또는 trained annotator) 소규모 스터디로 정렬 검증
42. Intervention(ablations/amplification): 뉴런 조작이 다운스트림 예측에 주는 영향(necessity/sufficiency)
43. Spatial insertion/deletion: 중요한 패치 제거/삽입에 따른 성능 변화 곡선
44. Calibration & DCA: 임상 모델로 확장할 경우 신뢰성/의사결정 관점 강화

9.3 논문 본문에 들어갈 ‘핵심 그림’ 추천 세트

- Fig-1: PathoSAEv3 파이프라인(Backbone $\rightarrow$ SAE $\rightarrow$ concept cards/heatmaps $\rightarrow$ barcode/probe)
- Fig-2: 4 variant Pareto front (MSE/R2 vs L0) + error bars
- Fig-3: Entropy 분포 비교(PLUTO 스타일) + monosemantic neuron count barplot
- Fig-4: Variant 별 대표 concept card + heatmap overlay(공간적 증거)
- Fig-5: (선택) barcode 분류 성능 vs threshold sweep(CytoSAE 스타일)
- Fig-6: (선택) universality matching 결과(heatmap + percent)

10. 구현 큰그림 (모듈, 데이터, 산출물, 시각화 템플릿)

PathoSAEv3 는 이미 training/evaluation/visualize 구조를 갖추고 있으므로, 아래 기능을 모듈 단위로 추가하면 논문 실험을 반복 가능하게 자동화할 수 있다.

10.1 추가를 권장하는 모듈

모듈	역할	주요 산출물
evaluation/hif.py	HIF 계산 및 로딩(세포/핵/색상 통계)	hif_features.parquet/csv
evaluation/monosemanticity_entropy.py	HIF-entropy 기반 단의미성 계산	entropy_per_neuron.csv, entropy_hist.png
evaluation/sparse_probe.py	k-sparse probe 학습/평가	probe_results.csv, probe_r2_plot.png
evaluation/universality.py	SAE 간 feature matching(Hungarian)과 universality 비율	matching_matrix.npy, universality_summary.json
evaluation/ms_score.py	VLM-style MS 계산(보조 인코더 기반)	ms_per_neuron.csv, ms_hist.png
evaluation/barcode.py	slide/patient concept barcode 생성	barcodes.csv
evaluation/barcode_classifier.py	barcode 기반 임상 라벨 분류	roc/pr curves, metrics.json
evaluation/intervention.py	ablation/amplification/insertion-deletion	intervention_curves.png, delta_logit_stats.csv

10.2 데이터 스키마(권장)

패치 단위 activation 을 저장할 때, 나중에 barcode/robustness/외부 검증을 하려면 메타데이터가 중요하다.

- 필수: patch_id, slide_id, patient_id, stain, scanner, dataset_name, (x,y) 좌표(가능하면)
- activation 저장: float16/float32 선택(평가에는 float32 가 안전), 대규모면 chunked 저장(zarr/parquet) 고려
- HIF 저장: patch_id 키로 join 가능하게

10.3 결과 폴더 구조(권장)

```
results/  
run_{variant}_{seed}/  
  metrics.json  
  activation_hist.png  
  sparsity_dist.png  
  concept_cards/  
    neuron_01234.png  
  ...
```

heatmaps/
 neuron_01234_tile_0001.png
comparison/
 comparison_table.csv
 pareto_mse_l0.png
 pareto_r2_l0.png
entropy/
 entropy_hist.png
 monosemantic_count.png
probes/
 probe_results.csv
 probe_r2_k_sweep.png
universality/
 match_percent.json
 match_heatmap.png
ms/
 ms_hist.png
 ms_vs_entropy.png
barcode/
 barcodes.csv
 clf_metrics.json
 roc_curve.png

10.4 시각화 템플릿(논문에 바로 쓰는 그래프)

- Pareto plot: x 축=L0, y 축=MSE 또는 1-R2, variant 별 점+오차막대
- Entropy boxplot/violin: SAE vs baseline(원래 임베딩) 비교 + long-tail 강조
- Probe 성능 plot: k-sweep 에 따른 R2/AUROC 곡선(SAE vs baseline)
- UMAP+HDBSCAN: (선택) 뉴런 클러스터 시각화 + 클러스터 대표 concept card
- Heatmap overlay: 한 개념 뉴런에 대해 (원본 타일, heatmap, top patches) 한 Figure 로 묶기
- Universality heatmap: SAE A 뉴런 vs SAE B 뉴런 상관 행렬의 matched pair 강조

10.5 계산/리소스 고려사항

- MS/Coherence 는 $O(N^2)$ similarity 가 병목이므로, N 을 줄이거나 random pair sampling/mini-batch 누적을 사용
- HIF 계산(특히 cell/nucleus)은 시간이 오래 걸릴 수 있으므로 캐싱 필수
- concept card 생성은 전체 뉴런(24,576) 전부가 아니라, (활성 빈도 상위 / entropy 하위 / MS 상위)처럼 ‘선별’이 현실적

11. 체크리스트 (논문 제출용)

아래 항목을 채우면, '실험/검증이 부족하다'는 리뷰 코멘트를 크게 줄일 수 있다.

11.1 재현성/공정 비교

- 4 개 variant 모두 동일 데이터/epoch/lr/batch/expansion factor 사용
- seed 반복(≥ 3) 수행 및 평균±표준편차 보고
- 하이퍼파라미터와 코드/실험 설정을 표로 정리(appendix 가능)

11.2 해석가능성(정량+정성) 증거

- Concept card(Top patches) 예시를 충분히 제시(대표 + 실패 사례 포함)
- Entropy 기반 단의미성 분포 + monosemantic neuron 비율
- 가능하면 MS 또는 coherence 같은 HIF-free 지표 추가
- UMAP/클러스터링(선택): dictionary 가 구조화됨을 보여줌

11.3 의학적 증빙/임상 유용성

- Confounder robustness(스캐너/염색/기관 예측 불가) 또는 domain shift 안정성
- Barcode/probe 기반 임상 라벨 예측 성능(AUROC/F1) + baseline 대비
- 외부 검증(가능하면): 다른 코호트에서 동일 결론 재현
- 전문가 평가 프로토콜 + 평가자 간 일치도

11.4 충실도/인과(가능하면 강력)

- Ablation/amplification 으로 예측 변화가 개념적으로 타당함을 보임
- Spatial insertion/deletion curve 로 heatmap 설명의 충실도 검증

11.5 한계/부정 결과도 포함

- Sparse probe 가 항상 좋아지지 않을 수 있음(PLUTO 논문 결과) → 정직하게 보고하고 해석
- Feature splitting/redundancy 가능성 → 추가 분석(상관 행렬)로 설명
- HIF 정의/추출이 imperfect 할 수 있음 → sensitivity 분석 또는 대안(HIF-free MS) 병행

12. 참고 문헌 / 출처

- Dasdelen et al. CytoSAE: Interpretable Cell Embeddings for Hematology. (PDF 첨부: cytosae.pdf)
- Evaluating the Utility of Sparse Autoencoders for Interpreting Pathology Foundation Models. (PDF 첨부: 10_Evaluating_the_Utility_of_S (1).pdf)
- Pach et al. Sparse Autoencoders Learn Monosemantic Features in Vision-Language Models. (PDF 첨부)
- PathoSAEv3 프로젝트 설계 문서(pathoSAEv3.md).

추가로 본 문서에서 제안한 일부 지표(예: calibration, DeLong test, insertion/deletion)는 의학 AI/설명 가능 AI 분야에서 널리 쓰이는 표준 평가 방법을 기반으로 한다.